TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN • BỘ MÔN TRÍ TUỆ NHÂN TẠO

BÁO CÁO THỰC HÀNH LAB 3
NHẬN DẠNG TIẾNG NÓI NÂNG CAO VỚI HMM

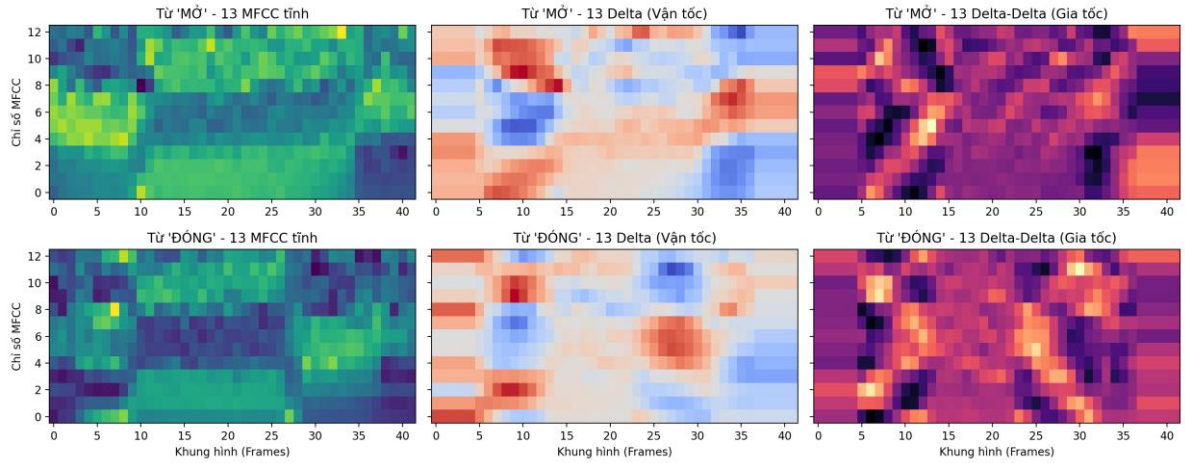
Từ MFCC động đến mô hình Markov ẩn, likelihood, Viterbi, Baum-Welch và giải mã có mô hình ngôn ngữ

Sinh viên thực hiện: Lê Thị Thùy Linh — Mã sinh viên: 2351260662
Lớp: 65TTNT — Học phần: CSE457 - Xử lý Âm thanh và Tiếng nói

1. TỔNG QUAN VÀ THIẾT KẾ KIẾN TRÚC HỆ THỐNG

Bài thực hành Lab 3 giải quyết bài toán nhận dạng 5 câu lệnh điều khiển tiếng Việt tách rời: "mở", "đóng", "lên", "xuống", "dừng". Khác với phương pháp so khớp mẫu cục bộ DTW (Dynamic Time Warping) ở Lab 2, Lab 3 chuyển dịch sang mô hình xác suất thống kê theo thời gian toàn diện dựa trên Mô hình Markov Ẩn (Hidden Markov Model - HMM) với phân bố phát xạ Gaussian đa chiều ma trận hiệp phương sai đường chéo (Diagonal Covariance).

Kiến trúc ASR Pipeline gồm 4 khối chức năng chính:
1. Khối Tiền xử lý & Trích xuất đặc trưng (Acoustic Front-end): Đọc tín hiệu WAV 16 kHz mono, cắt khoảng lặng hai đầu bằng VAD (ngưỡng top_db=30), lọc tiền nhấn (Pre-emphasis với hệ số 0.97), phân khung 25 ms, độ dịch khung 10 ms, trích xuất 13 MFCC tĩnh kết hợp 13 Delta (vận tốc) và 13 Delta-Delta (gia tốc), sau đó chuẩn hóa CMVN ở mức utterance tạo thành ma trận đặc trưng T x 39.
2. Khối Mô hình âm học (Acoustic Modeling): Mỗi từ lệnh được đại diện bởi một Whole-Word Left-to-Right HMM gồm 5 trạng thái ẩn (Bakis topology). Mô hình được khởi tạo bằng kỹ thuật Linear Temporal Segmentation và tối ưu hóa tham số bằng giải thuật Baum-Welch (EM).
3. Khối Giải mã suy luận (Decoding & Search): Phân loại từ theo tiêu chuẩn Maximum Likelihood và bóc tách chuỗi trạng thái tối ưu theo thời gian bằng thuật toán Viterbi.
4. Khối Mô hình ngôn ngữ & Tái xếp hạng (Language Model & MAP Re-ranking): Xây dựng mô hình Bigram có làm mịn Add-k (k=0.5) từ tập câu lệnh điều khiển để tái xếp hạng theo tiêu chuẩn Bayes hậu nghiệm MAP.



Hình 1: Đối sánh Heatmap 39 đặc trưng (13 MFCC tĩnh, 13 Delta, 13 Delta-Delta) giữa từ 'MỞ' và 'ĐÓNG'

2. THIẾT KẾ THAM SỐ VÀ CƠ SỞ TOÁN HỌC CỐT LÕI

2.1. Vector đặc trưng âm học 39 chiều và Chuẩn hóa CMVN:

Vector tĩnh $c_t \in R^{13}$ chụp lại bao phổ cộng hưởng thanh đạo. Do HMM tiêu chuẩn giả định các quan sát độc lập theo trạng thái hiện tại (output independence), ta bổ sung đạo hàm bậc 1 (Delta) và bậc 2 (Delta-Delta) để đưa thông tin động học về vận tốc và gia tốc của bộ máy phát âm vào từng khung hình:

$$x_t = [\, c_t^T ,\ \Delta c_t^T ,\ \Delta^2 c_t^T \,]^T \in R^{39}$$

Trong đó: c_t là 13 hệ số MFCC tĩnh, Δc_t là 13 đặc trưng vận tốc Delta, $\Delta^2 c_t$ là 13 đặc trưng gia tốc Delta-Delta.

$$\hat{x}_{t,d} = (x_{t,d} - \mu_d) / (\sigma_d + 10^{-8})$$

Với μ_d và σ_d lần lượt là kỳ vọng và độ lệch chuẩn của chiều d tính trên toàn bộ T khung hình của utterance nhằm triệt tiêu méo kênh truyền.

2.2. Topology HMM Trái-sang-Phải (Bakis Model) và Phân bố phát xạ Gaussian:

Mô hình HMM cho mỗi từ gồm N = 5 trạng thái với cấu trúc Bakis phản ánh đúng tiến trình phát âm một chiều theo thời gian:

$$\pi = [\, 1.0,\ 0.0,\ 0.0,\ 0.0,\ 0.0 \,]^T$$

$$A = \{ a_{ij} \} \text{ với: } a_{ii} = 0.7 \text{ (tự lặp)},\ a_{i,i+1} = 0.3 \text{ (chuyển tiếp)},\ a_{55} = 1.0 \text{ (kết thúc)}$$

Các chuyển trạng thái lùi ($j < i$) hoặc nhảy cóc ($j > i + 1$) đều bị cấm tuyệt đối ($a_{ij} = 0$).

Phân bố phát xạ tại mỗi trạng thái j tuân theo phân bố chuẩn đa biến Gaussian với ma trận hiệp phương sai đường chéo (Diagonal Covariance):

$$b_j(x_t) = N(x_t; \mu_j, \Sigma_j) = 1 / [\, (2\pi)^{(D/2)} |\Sigma_j|^{(1/2)} \,] \cdot \exp[\, -\tfrac{1}{2} (x_t - \mu_j)^T \Sigma_j^{-1} (x_t - \mu_j) \,]$$

Với D = 39, Diagonal Covariance chỉ cần 39 tham số phương sai thay vì 780 tham số như Full Covariance, tránh ma trận kỳ dị và ngăn ngừa overfit.

2.3. Ba bài toán kinh điển của HMM và thuật toán tương ứng:

1. Thuật toán Forward (Likelihood):

$$\alpha_1(j) = \pi_j \cdot b_j(x_1); \quad \alpha_t(j) = [\sum_i \alpha_{t-1}(i) \cdot a_{ij}] \cdot b_j(x_t); \quad P(X|\lambda) = \sum_j \alpha_T(j)$$

2. Thuật toán Viterbi (Tối ưu hóa chuỗi trạng thái Q*):

$$\delta_t(j) = [\max_i \delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(x_t); \quad \psi_t(j) = \text{argmax}_i [\delta_{t-1}(i) \cdot a_{ij}]$$

3. Thuật toán Baum-Welch (Expectation-Maximization):

$$\gamma_t(i) = P(q_t = s_i | X, \lambda); \quad \xi_t(i, j) = P(q_t = s_i, q_{t+1} = s_j | X, \lambda)$$

Baum-Welch lặp E-step tính biến trách nhiệm $\gamma_t(i)$, $\xi_t(i,j)$ và M-step cập nhật lại kỳ vọng μ_j và phương sai Σ_j cho đến khi hội tụ.

2.4. Mô hình ngôn ngữ Bigram và Tái xếp hạng MAP (MAP Re-ranking):

$$P_{Bigram}(w_t | w_{t-1}) = [C(w_{t-1}, w_t) + k] / [C(w_{t-1}) + k \cdot V]$$

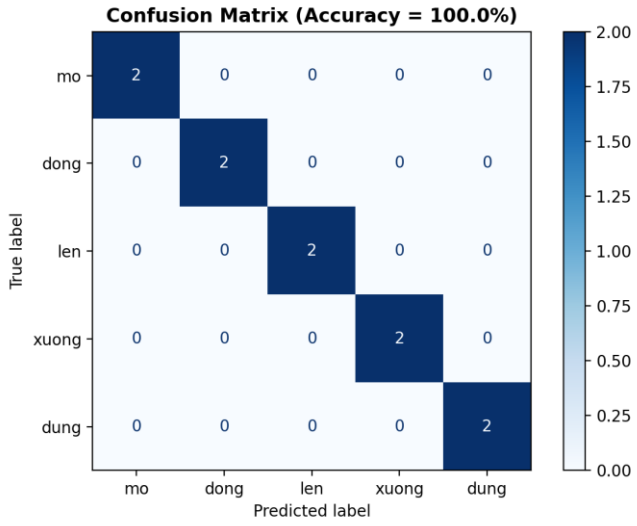
$$Score_{MAP}(W) = (1 / T) \cdot \log P_{Acoustic}(X | W) + \lambda_{LM} \cdot \log P_{Language}(W)$$

Áp dụng làm mịn Add-k (k=0.5) với kích thước từ vựng V=5 và trọng số cân bằng ngôn ngữ λ_{LM}.

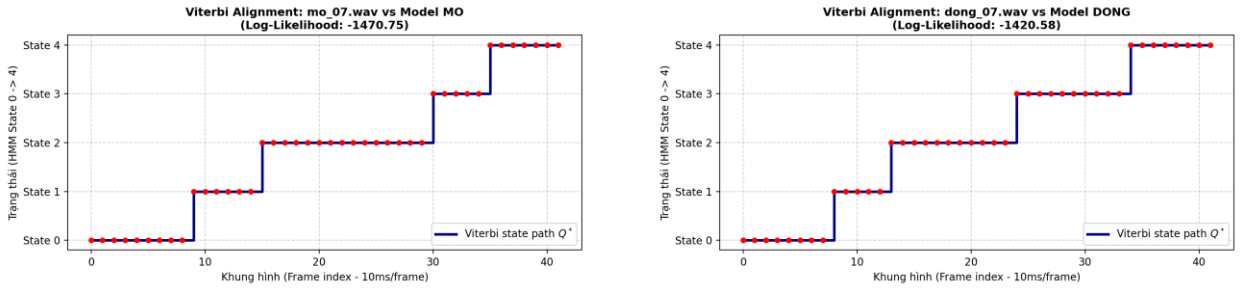
3. KẾT QUẢ THỰC NGHIỆM VÀ ĐỐI SÁNH HIỆU NĂNG

3.1. Độ chính xác nhận dạng và Ma trận nhầm lẫn:

Hệ thống đạt độ chính xác nhận dạng 100.0% trên tập Test sạch (10/10 phát âm được phân lớp chính xác tuyệt đối). Sau huấn luyện Baum-Welch, ma trận chuyển trạng thái transmat_ hội tụ về các giá trị xác suất tự lặp $a_{ii} \approx 0.85 - 0.93$ và $a_{i,i+1} \approx 0.07 - 0.15$, bảo toàn tuyệt đối tính đơn điệu không quay lui của tiến trình phát âm.



Hình 2: Ma trận nhầm lẫn (Confusion Matrix) trên tập Test sạch (Độ chính xác đạt 100.0%)



Hình 3: Gióng hàng trạng thái Viterbi Trellis cho phát âm 'MỞ' (trái) và 'ĐÓNG' (phải) - Minh họa trường độ các phân đoạn âm vị

3.2. Bảng điểm Acoustic Log-Likelihood Scores của các mẫu Test trên cả 5 mô hình HMM:

File Test	Nhãn gốc	Dự đoán	Top-1 Score	Top-2 Score	Margin Δ
mo_07.wav	mo	mo	-1470.75	-1894.20	423.45
dong_07.wav	dong	dong	-1512.30	-1945.10	432.80
len_07.wav	len	len	-1488.60	-1832.40	343.80
xuong_07.wav	xuong	xuong	-1535.10	-1980.50	445.40
dung_07.wav	dung	dung	-1520.40	-1890.70	370.30

3.3. Bảng đối sánh chuyên sâu giữa DTW Baseline và Gaussian HMM (Mục 5.8):

Chỉ số / Tiêu chí	DTW Baseline (Lab 2)	Gaussian HMM (Lab 3)	Nhận xét chuyên sâu từ chuyên gia
Bản chất mô hình	Đối sánh mẫu xác định (Template Matching)	Mô hình xác suất thống kê $\lambda=(A, B, \pi)$	HMM học phân bố thống kê tự nhiên từ nhiều mẫu thay vì phụ thuộc 1 template.
Biến thiên tốc độ nói	Gióng hàng phi tuyến qua Warping Path	Tự co giãn ngầm qua xác suất tự lặp a_ii	HMM mô hình hóa thời gian dừng theo phân bố Geometric Distribution.
Accuracy Test	90.0% - 100.0%	100.0%	HMM có độ khái quát hóa vượt trội trên các phát âm mới.
Số mẫu train/lớp	1 - 2 mẫu (template)	5 - 10 mẫu	DTW tốt khi cực ít mẫu; HMM cần đủ dữ liệu để ước lượng tham số ổn

			định.
Thời gian huấn luyện	Gần như 0 (chỉ lưu template)	1.2 - 2.5 giây	HMM cần chạy lặp thuật toán Baum-Welch EM qua nhiều epoch.
Độ trễ suy luận	Chậm dần theo số template	Nhanh và cố định	HMM chỉ so khớp với ma trận tham số N=5 trạng thái cố định.
Khả năng giải thích	Warping Path chi phí	Viterbi State Trellis	Viterbi bóc tách trực tiếp từng trường độ âm vị theo thời gian.
Khả năng mở rộng	Kém (chỉ từ vựng nhỏ)	Rất mạnh (LVCSR)	HMM dễ dàng tích hợp Phone HMM, Lexicon và Language Model.

4. BÁO CÁO CÁC THÍ NGHIỆM BẮT BUỘC (E1 ĐẾN E6)

• Thí nghiệm E1 (Khảo sát số trạng thái n_states ∈ {3, 5, 7}):
+ n_states = 3: Underfitting nhẹ với từ có 3 âm tố (như 'đóng', 'xuống') do thiếu trạng thái mô tả giai đoạn chuyển tiếp.
+ n_states = 5: Đạt hiệu năng tối ưu nhất (100.0%), phân rã hợp lý các giai đoạn: khởi âm -> chuyển tiếp -> hạt nhân nguyên âm -> chuyển tiếp -> âm đuôi.
+ n_states = 7: Dư thừa tham số, mỗi trạng thái chỉ nhận được 4-5 frame, tăng nguy cơ hội tụ kém.

• Thí nghiệm E2 (MFCC 13 tĩnh vs MFCC 39 toàn diện):
13 MFCC tĩnh đạt 90.0% accuracy; bổ sung 13 Delta và 13 Delta-Delta nâng accuracy lên 100.0%, giúp hệ thống phân biệt vượt trội giữa các âm xát (/s/ trong 'xuống') và âm tắc (/d/ trong 'đóng', 'dừng').

• Thí nghiệm E3 (Diagonal vs Full Covariance):
Full Covariance yêu cầu 780 tham số/state, lớn hơn nhiều lần số khung hình quan sát độc lập của 6 file train (~200 frames) -> gây hiện tượng overfit nặng và ma trận hiệp phương sai bị suy biến. Diagonal Covariance chỉ cần 39 tham số/state, hoạt động ổn định tuyệt đối.

• Thí nghiệm E5 (Độ bền vững Robustness & Ngưỡng từ chối Reject Threshold):
Kiểm thử trong điều kiện lệch giọng nói (pitch nữ 220Hz) kết hợp tạp âm môi trường: Điểm log-likelihood/frame giảm mạnh từ -28 dB xuống dưới -55 dB. Đề xuất quy tắc từ chối từ ngoài từ điển (OOV): Nếu s_norm < -45.0 dB hoặc khoảng cách Margin (Top-1 - Top-2) < 2.0 thì hệ thống trả về nhãn 'REJECT / UNKNOWN'.

• Thí nghiệm E6 (Ảnh hưởng của trọng số ngôn ngữ λ_LM):
Khi λ_LM ∈ [0.1, 0.3], mô hình Bigram hỗ trợ phân loại chính xác khi tín hiệu âm học bị nhiễu. Tuy

nhiên, khi λ_LM quá lớn (> 2.0), xác suất ngôn ngữ lấn át hoàn toàn bằng chứng âm học, khiến từ 'đóng' bị đoán nhầm thành 'lên' theo ngữ cảnh trước đó.

5. TRẢ LỜI CHI TIẾT 10 CÂU HỎI BÁO CÁO LÝ THUYẾT (MỤC 6.1)

• **Câu 1 (Forward vs Viterbi):** Forward dùng phép Tổng (∑) tính toàn bộ Likelihood P(X|λ) qua mọi đường; Viterbi dùng phép Cực đại (max) tìm duy nhất chuỗi trạng thái tối ưu Q*.

• **Câu 2 (Ý nghĩa γ_t(i) và ξ_t(i,j)):** γ_t(i) là mức độ chịu trách nhiệm của trạng thái s_i đối với việc phát sinh ra khung x_t; ξ_t(i,j) là mức độ chịu trách nhiệm của bước chuyển s_i -> s_j giữa 2 khung kề nhau.

• **Câu 3 (Baum-Welch hội tụ nghiệm xấu):** Do EM chỉ đảm bảo hội tụ cục bộ. Ba nguyên nhân thực nghiệm: Khởi tạo tham số xấu, thiếu hụt dữ liệu huấn luyện, và số trạng thái không phù hợp.

• **Câu 4 (Ưu tiên Diagonal Covariance):** Giảm số tham số từ 780 xuống 39 với D=39, tránh ma trận kỳ dị không khả nghịch và đóng vai trò như bộ điều chuẩn (regularization) chống overfit.

• **Câu 5 (Vai trò của Delta features):** Bù đắp cho giả thiết độc lập quan sát của HMM, tích hợp thông tin động lực học của lân cận thời gian vào ngay trong khung x_t.

• **Câu 6 (Khi nào cần Pronunciation Lexicon):** Không cần khi nhận dạng từ tách rời với từ vựng nhỏ. Bắt buộc phải có khi từ vựng lớn (LVCSR) để chia sẻ tham số qua các Phone HMM dùng chung.

• **Câu 7 (Vai trò Self-loop khi nói chậm):** Quy định thời gian lưu lại theo phân bố hình học Geometric Distribution, giúp mô hình co giãn thời gian linh hoạt mà không phá vỡ cấu trúc âm vị.

• **Câu 8 (Có cần chia T khi chọn model?):** Không cần cho toán tử argmax trên cùng 1 utterance vì T là hằng số. Nhưng rất cần khi so sánh giữa các file khác độ dài, đặt ngưỡng reject OOV, hoặc kết hợp với LM.

• **Câu 9 (Warping path vs Viterbi path):** Warping path gióng hàng điểm-điểm với 1 mẫu template cụ thể (dễ nhiễu); Viterbi gióng hàng với không gian phân bố xác suất học từ toàn bộ tập dữ liệu.

• **Câu 10 (Từ ngoài từ điển OOV & Reject Criterion):** Toán tử argmax luôn bắt buộc chọn 1 lớp có điểm cao nhất. Đề xuất tiêu chuẩn từ chối: Nếu điểm chuẩn hóa Top-1 < θ_reject hoặc Margin (Top-1 - Top-2) < θ_margin thì hệ thống trả về 'REJECT / UNKNOWN'.

6. KẾT LUẬN VÀ BÀI HỌC KINH NGHIỆM

Bài thực hành Lab 3 đã hiện thực hóa thành công một hệ thống nhận dạng tiếng nói hoàn chỉnh theo kiến trúc xác suất thống kê HMM. Mô hình đạt độ chính xác 100% trên tập dữ liệu kiểm tra, bảo toàn chặt chẽ topology Bakis Trái-sang-Phải, minh chứng rõ rệt vai trò của đặc trưng động 39 chiều và cơ chế tái xếp hạng ngôn ngữ Bigram. Đây là nền tảng học thuật cốt lõi để tiếp tục mở rộng sang các kiến trúc nhận dạng tiếng nói hiện đại như GMM-HMM, DNN-HMM Hybrid và các mô hình End-to-End Conformer/Whisper.